

Data Science e Tecnologie per le Basi di Dati Esame del 22 Febbraio 2024

Iniziato

Terminato

Tempo impiegato 1 ora 35 min.

Valutazione

Domanda 1

Risposta errata

Punteggio ottenuto -0,23 su 1,50

1.5 punti (-15% di penalità per ogni risposta sbagliata)

Sono date le seguenti transazioni:

E, B, C, D

B, E

B, A

C, E

B, E, D

F, A, E, D, B, C

B, E, A, F, D, C

C, B

E, D, A, B, F

F, D, A, B, E

Si crei un FP-Tree con MinSup > 3 (un itemset è frequente se compare in più di 3 transazioni) per le transazioni precedenti. In caso di item con uguale supporto, utilizzare l'ordine lessicografico (per es. se A = 2 e B = 2, A precede B).

Indicare il pattern e il rispettivo supporto contenuti nel C-CPB (C Conditional Pattern Base).

Le risposte sono nel formato Pattern:Supporto.

(a) B: 2

3/15/24 12:07 PM Pagina 1 di 40

- ⊙ (b) A, B: 1 💢
- C (c) A, D, E, B: 1
- (d) D, E, B: 1
- (e) D, E, B: 2
- (g) E: 2
- (h) D, E, B: 3

La risposta corretta è: D, E, B: 1

3/15/24 12:07 PM Pagina 2 di 40

Domanda 2

Risposta non data

Punteggio max.: 2,00

2 punti (-15% di penalità per ogni risposta sbagliata)

Abbiamo a disposizione 5 punti con le seguenti coordinate (x, y):

- A (2, 4)
- B (0, 4)
- C(4, 2)
- D (6, 2)
- E(0, 0)

Vogliamo applicare il clustering di tipo K-Means per 2 iterazioni con i seguenti centroidi iniziali: (0, 0) e (5, 5). La metrica di distanza è: $d(a, b) = |(x_a - x_b)| + |y_a - y_b|$ dove a e b sono due punti.

Quali cluster si ottengono?

- (a) Nessuna risposta è corretta
- (b) {B, A} {E, C, D}
- (c) {A, B, D} {C, E}
- (d) {A, B, E} {C, D}
- (e) {D, E} {A, B, C}
- (f) {E, B} {A, C, D}
- (g) {D, A} {B, C, E}
- (h) {A, E } { B, C, D }

La risposta corretta è: {E, B} {A, C, D}

Domanda 3

Completo

Punteggio ottenuto 2,00 su 3,00

3 punti (nessuna penalità per risposta sbagliata)

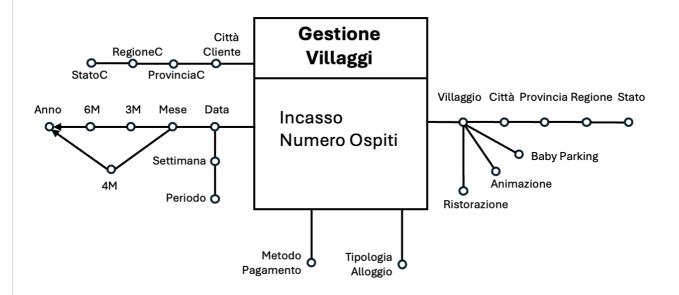
3/15/24 12:07 PM Pagina 3 di 40

Un'azienda turistica che possiede diversi villaggi vuole analizzare il rendimento di ciascun villaggio. I villaggi sono dislocati in diverse aree del mondo, di cui sono note le informazioni geografiche (città, provincia, regione, stato). Per ogni villaggio sono noti a priori i servizi che potrebbero essere offerti (ristorazione, animazione e baby parking), memorizzati sotto forma di configurazione booleana.

Le tariffe dipendono dalla tipologia di alloggio (ad esempio bungalow, bilocale, trilocale) e dalla settimana. Le settimane sono raggruppate in periodi (per esempio, periodo di alta stagione). Per i clienti dei villaggi si considera l'informazione geografica di provenienza (città, provincia, regione, stato). E' inoltre memorizzato il metodo di pagamento (carta di credito, bonifico, assegno).

Si analizzano le informazioni sull'incasso e sul numero di ospiti con granularità giornaliera. Inoltre si considerano mese, trimestre (3M), quadrimestre (4M), semestre (6M), anno.

Il data warehouse è caratterizzato dal seguente schema concettuale e dal corrispondente schema logico.



VILLAGGIO(<u>CodV</u>, Villaggio, CittàV, ProvinciaV, RegioneV, StatoV, Ristorazione, Animazione, BabyP arking)

TEMPO(CodT, Data, Mese, 3M, 4M, 6M, Anno, Settimana, Periodo)

JUNK-ALLOGGIO-PAGAMENTO(**CodAP**, TipologiaAlloggio, ModalitàPagamento)

CARATTERISTICHE-CLIENTE(CodCC, CittàCliente, ProvinciaC, RegioneC, StatoC)

GESTIONE-VILLAGGI(CodV, CodT, CodAP, CodCC, Incasso, NumOspiti)

Considerando la gestione dei villaggi dal 2014 al 2023, visualizzare per ogni tipologia alloggio, regione in cui è sito il villaggio e semestre (6M),

- l'incasso medio giornaliero e il numero complessivo di ospiti
- la percentuale dell'incasso rispetto al complessivo annuale.

Associare ad ogni record:

3/15/24 12:07 PM Pagina 4 di 40

- un rango rispetto all'incasso medio giornaliero (il valore 1 al record con il più basso valore di incasso medio giornaliero), separatamente per Stato in cui è sito il villaggio
- Un rango per numero complessivo di ospiti (il valore 1 al record con il più alto).

SELECT TipologiaAlloggio, RegioneV, 6M,

SUM(NumOspiti),

SUM(Incasso)/COUNT (DISTINCT Data),

100*SUM(Incasso)/SUM(SUM(Incasso)) OVER(PARTITION BY Anno ORDER BY 6M ROW PRECEDINGS UNBOUNDED),

RANK() OVER (PARTITION BY StatoV ORDER BY SUM(Incasso)/COUNT (DISTINCT Data)), RANK() OVER (ORDER BY SUM(NumOspiti) DESC)

FROM Villaggio=V, Tempo=T, JunkAlloggioPagamento=JAP, GESTIONE_VILLAGGI=GV WHERE V.CodV=GV.CodV AND GV.CodT=T.CodT AND GV.CodAP=JAP.CodAP AND T.Anno > 2013 AND T.Anno < 2024

GROUP BY TipologiaAlloggio, RegioneV, 6M, StatoV

SELECT TipologiaAlloggio, RegioneV, 6M, SUM(Incasso)/COUNT (DISTINCT Data), SUM(NumOspiti), 100*SUM(Incasso)/SUM(SUM(Incasso)) OVER (PARTITION BY TipologiaAlloggio, RegioneV, Anno), RANK() OVER (PARTITION BY StatoV ODER BY SUM(Incasso)/COUNT (DISTINCT Data)), RANK() OVER (ODER BY SUM(NumOspiti), DESC) FROM GESTIONE-VILLAGGIO GV, VILLAGGIO V, TEMPO T, JUNK-ALLOGGIO-PAGAMENTO JAP WHERE Anno>=2014 and Anno <=2023 AND GV.CodT=T.CodT AND JAP.CodAP=GV.CodAP AND V.CodV=GV.CodV GROUP BY TipologiaAlloggio, RegioneV, 6M, StatoV, Anno

Commento:

Manca Anno nella GB

Prima finestra di calcolo errata

3/15/24 12:07 PM Pagina 5 di 40

Domanda 4

Completo

Non valutata

Questa non è una domanda dell'esame

Puoi utilizzare l'area di testo sottostante per appunti o bozze (per esempio, per scrivere i passi intermedi di un esercizio).

Il testo inserito in questo esercizio non verrà considerato in fase di correzione dell'esame.

La 9 su mongo DB potrebbe essere la C ma non ricordo bene come siano assegnati i parametri nella "project", Ricordo che per assegnare il valore del campo "name" e "location" se non sbaglio si usi \$name e \$location mentre li assegna sempre "true".

Domanda 5

Risposta corretta

Punteggio ottenuto 1,00 su 1,00

Schema concettuale (1 punto, penalità -15% per ogni risposta sbagliata)

Si vogliono analizzare le informazioni relative ai servizi offerti da una catena di copisterie presenti in europa.

Ciascuna copisteria può offrire i seguenti diversi tipi di servizi: realizzazione di brochure, volantini, calendari, stampe fotografiche e fotocopie.

Le aziende che si rivolgono ad una copisteria possono effettuare un ordine per un certo tipo di servizio (ad esempio stampa di volantini), indicando una specifica quantità (ad esempio 10.000 volantini). Le aziende possono anche specificare se sono interessate ad una modalità di realizzazione di tipo «standard» o desiderano invece una modalità «express», al fine di ottenere il prima possibile il servizio richiesto. A discrezione dell'azienda, la consegna dei prodotti realizzati può essere effettuata dalla copisteria mediante un corriere, oppure essere a carico dell'azienda stessa. Ciascuna copisteria è convenzionata con diverse società di spedizione per gestire la consegna degli ordini.

Le aziende sono caratterizzate dal tipo di azienda (quale ad esempio azienda di consulenza IT, azienda di catering, agenzia immobiliare, etc. ...) e il settore di riferimento per quel tipo di azienda (quale ad esempio settore ICT, settore food, settore immobili, etc. ...).

3/15/24 12:07 PM Pagina 6 di 40

Si vogliono analizzare il costo medio per ordine e il tempo medio di realizzazione per ordine, in base alle seguenti informazioni:

- la copisteria, i tipi di servizio disponibili presso la copisteria (uno o più valori tra «brochure», «volantini», «calendari», «stampa_foto», «fotocopie»), e la lista di tutte le società di spedizione con cui la copisteria è convenzionata. Per ciascuna copisteria è anche nota la localizzazione geografica, espressa in termini di città, provincia, regione e stato.
- il tipo di azienda che ha richiesto il servizio (ad esempio azienda di consulenza IT o azienda di catering o agenzia immobiliare, etc. ...) e il settore di riferimento per quel tipo di azienda (ad esempio settore ICT o settore food o settore immobili, etc. ...)
- localizzazione geografica dell'azienda che ha richiesto il servizio, espressa in termini di città, provincia, regione e stato
- tipo di servizio richiesto
- la modalità di realizzazione richiesta (un valore tra «standard e «express»)
- data, giorno della settimana, mese, giorno del mese, trimestre, quadrimestre, anno in cui è l'azienda ha effettuato l'ordine
- tipo di pagamento (un valore tra «bonifico» e «carta di credito»)
- tipo di consegna (un valore tra «mediante società spedizioni» e a «carico dell'azienda»)

Selezionare dall'elenco tutti e soli gli attributi necessari per modellare correttamente le misure nella tabella dei fatti richieste dalle specifiche (sono possibili più risposte corrette poiché possono essere necessarie più misure).

Scegli una o più alternative:
(a) Tempo totale di realizzazione per tipo di pagamento
(c) Numero massimo di ordini
(d) Costo complessivo
(e) Costo medio
(f) Numero complessivo di ordini 🗸
(g) Tempo medio di realizzazione

Risposta corretta.

La risposta corretta è: Tempo totale di realizzazione, Numero complessivo di ordini, Costo complessivo

Domanda 6

3/15/24 12:07 PM Pagina 7 di 40

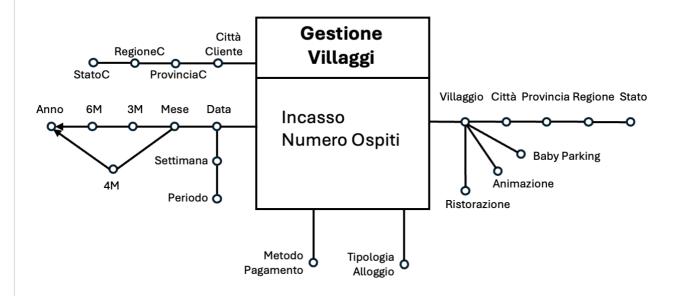
4 punti (nessuna penalità per risposta sbagliata)

Un'azienda turistica che possiede diversi villaggi vuole analizzare il rendimento di ciascun villaggio. I villaggi sono dislocati in diverse aree del mondo, di cui sono note le informazioni geografiche (città, provincia, regione, stato). Per ogni villaggio sono noti a priori i servizi che potrebbero essere offerti (ristorazione, animazione e baby parking), memorizzati sotto forma di configurazione booleana.

Le tariffe dipendono dalla tipologia di alloggio (ad esempio bungalow, bilocale, trilocale) e dalla settimana. Le settimane sono raggruppate in periodi (per esempio, periodo di alta stagione). Per i clienti dei villaggi si considera l'informazione geografica di provenienza (città, provincia, regione, stato). E' inoltre memorizzato il metodo di pagamento (carta di credito, bonifico, assegno).

Si analizzano le informazioni sull'incasso e sul numero di ospiti con granularità giornaliera. Inoltre si considerano mese, trimestre (3M), quadrimestre (4M), semestre (6M), anno.

Il data warehouse è caratterizzato dal seguente schema concettuale e dal corrispondente schema logico.



VILLAGGIO(<u>CodV</u>, Villaggio, CittàV, ProvinciaV, RegioneV, StatoV, Ristorazione, Animazione, BabyP arking)

TEMPO(**CodT**, Data, Mese, 3M, 4M, 6M, Anno, Settimana, Periodo)

JUNK-ALLOGGIO-PAGAMENTO(**CodAP**, TipologiaAlloggio, ModalitàPagamento)

CARATTERISTICHE-CLIENTE(CodCC, CittàCliente, ProvinciaC, RegioneC, StatoC)

GESTIONE-VILLAGGI(CodV, CodT, CodAP, CodCC, Incasso, NumOspiti)

Considerando i clienti italiani, visualizzare per ogni provincia in cui è sito il villaggio e mese,

3/15/24 12:07 PM Pagina 8 di 40

- l'incasso medio per ospite
- la percentuale del numero di ospiti rispetto al complessivo semestrale
- l'incasso complessivo indipendentemente dalla provincia in cui è sito il villaggio e mese
- Il numero complessivo di ospiti indipendentemente dalla provincia in cui è sito il villaggio

Si effettui l'analisi separatamente per Città del Cliente.

SELECT ProvinciaV, CittàCliente, Mese,

SUM(Incasso)/SUM(NumOspiti),

100*SUM(NumOspiti)/SUM(SUM(NumOspiti)) OVER (PARTITION BY 6M ORDER BY Mese ROW PRECEDINGS UNBOUNDED),

SUM(SUM(Incasso)) OVER (PARTITION BY CittàCliente, Mese),

FROM Villaggio=V, TEMPO=T, CARATTERISTICHE_CLIENTE=CC, GESTIONE_VILLAGGI=GV WHERE T.CodT=GV.CodT AND GV.CodV=V.CodV AND GV.CodCC=CC.CodCC

AND CC.StatoC="Italia"

GROUP BY PRovinciaV, CittàCliente, Mese

SELECT CittàCliente, ProvinciaV, Mese, 6M, SUM(Incasso)/SUM(NumOspiti), 100*SUM(NumOspiti)/SUM(SUM(NumOspiti)) OVER (PARTITION BY CittàCliente, ProvinciaV, 6M), SUM(SUM(Incasso)) OVER (PARTITION BY CittàCliente), SUM(SUM(NumOspiti)) OVER (PARTITION BY CittàCliente, Mese) FROM GESTIONE-VILLAGGIO GV, VILLAGGIO V, TEMPO T, JUNK-ALLOGGIO-PAGAMENTO JAP, CARATTERISTICHE-CLIENTE CC WHERE StatoC='Italia' AND JAND GV.CodV=V.CodV AND GV.CodT=T.CodT AND GV.CodAP=JAP.CodAP AND GV.CodCC=CC.CodCC GROUP BY CittàCliente, ProvinciaV, Mese, 6M

Commento:

Manca un attributo nella GB

Prima finestra di calcolo diversi errori

un errore nella seconda finestra di calcolo

terza finestra di calcolo mancante

Domanda 7

Parzialmente corretta

Punteggio ottenuto 2,70 su 5,00

3/15/24 12:07 PM Pagina 9 di 40

5 punti totali (penalità -15% per ogni risposta sbagliata)

Sono date le seguenti tabelle:

Libro(CodL, Titolo, CodA, CodCE, Genere, AnnoPubblicazione, VotoMedio)

Autore(CodA, Nome, Cognome, Nazionalità, DataNascita)

Casa-Editrice(CodCE, NomeEditore, DataFondazione, NumeroImpiegati)

Lettore(CodLE, Nome, Cognome, TipoMembership, DataNascita)

Lettura(CodL, CodLE, DataUltimaLettura, VotoLettore)

Si assumano le seguenti cardinalità:

- card(LIBRO) = 6·10⁶ tuple
 valori distinti di Genere = 20
 fattore di riduzione di AverageRating>4.5 = 1/20
- card(AUTORE) = 3·10⁴ tuple
 valori distinti di Nazionalità = 100
 MIN(DataNascita) = 1/1/1910, MAX(DataNascita) = 31/12/1999
- card(CASA-EDITRICE) = 10² tuple
 valori distinti di NumeroImpiegati = 10
- card(LETTORE) = 4·10⁷ tuple
 MIN(DataNascita) = 1/1/1940, MAX(DataNascita) = 31/12/2009
 valori distinti di TipoMembership = 4
- card(LETTURA)= 12·10⁸ tuple

Inoltre, sono dati i seguenti fattori di riduzione per le clausole having:

Having COUNT(*)>2 = 1/5

Si consideri la seguente query:

3/15/24 12:07 PM Pagina 10 di 40

SELECT L.CodL, COUNT(*)

FROM Lettore LE, Lettura LTR, Libro L, Autore A, Casa-Editrice CE

WHERE LE.CodLE=LTR.CodLE AND L.CodA=A.CodA

AND L.CodCE=CE.CodCE AND LTR.CodL=L.CodL

AND LE.MembershipType='3-Anni'

AND CE.NumeroImpiegato='50-200'

AND A.DataNascita ≥ 1/1/1970

AND L.Genere='Thriller'

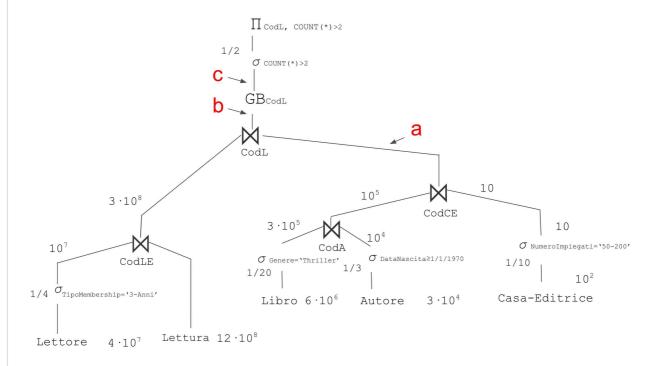
GROUP BY L.CodL

HAVING COUNT(*)>2

Cardinalità

(1.5 punti, penalità -15% per ogni risposta sbagliata)

La figura sottostante rappresenta il query tree per la query precedente.



Seleziona la risposta corretta per la cardinalita' di (a):

 $\circ 10^4 \checkmark \qquad \circ 10^5 \qquad \circ 5 \cdot 10^3$

 $0.2 \cdot 10^{5}$

Punteggio ottenuto 5,00 su 5,00

La risposta corretta è: 10⁴

3/15/24 12:07 PM Pagina 11 di 40 Seleziona la risposta corretta per la cardinalita' di (b):

- C 2·10⁴
- \circ 4 · 10³
- © 5·10⁴
- 5 ⋅10⁵
 ✓

Punteggio ottenuto 5,00 su 5,00

La risposta corretta è: 5 ·10⁵

Seleziona la risposta corretta per la cardinalita' di (c):

- $\bigcirc 4 \cdot 10^4$
- © 10⁴
- C 10⁵
- © 2·10⁵

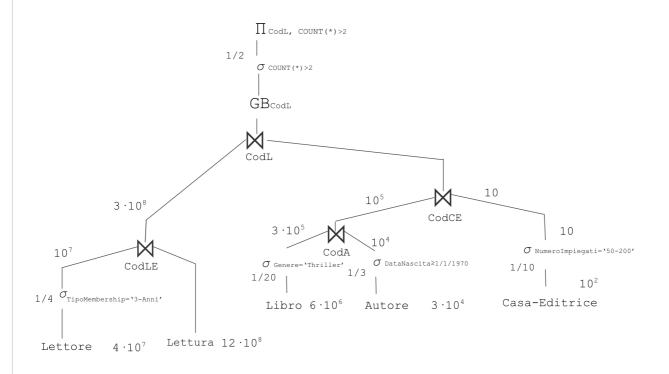
Punteggio ottenuto 5,00 su 5,00

La risposta corretta è: 10⁴

Indici

(1.5 punti, penalità -15% per ogni risposta sbagliata)

La figura sottostante rappresenta il query tree per la query precedente.



3/15/24 12:07 PM Pagina 12 di 40

Selezionare, per ogni tabella, le strutture fisiche accessorie per migliorare le prestazioni dell'interrogazione (se possibile) tra le opzioni di seguito.

Tabella LETTURA

- CREATE INDEX IndexA ON LETTURA(DataUltimaLettura) HASH
- C CREATE INDEX IndexB ON LETTURA(DataUltimaLettura) B+-Tree
- Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione √

Punteggio ottenuto 3,00 su 3,00

La risposta corretta è: Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione

Tabella LETTORE

- CREATE INDEX IndexD ON LETTORE(TipoMembership) B+-Tree
- Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione √
- C CREATE INDEX IndexC ON LETTORE(TipoMembership) HASH

Punteggio ottenuto 3,00 su 3,00

La risposta corretta è: Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione

Tabella LIBRO

- C CREATE INDEX IndexF ON LIBRO(Genere) B+-Tree
- CREATE INDEX IndexE ON LIBRO(Genere) HASH
- Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione

Punteggio ottenuto 3,00 su 3,00

La risposta corretta è: CREATE INDEX IndexE ON LIBRO(Genere) - HASH

Tabella AUTORE

Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione √

3/15/24 12:07 PM Pagina 13 di 40

- C CREATE INDEX IndexH ON AUTORE(DataNascita) B+-Tree
- C CREATE INDEX IndexG ON AUTORE(DataNascita) HASH

Punteggio ottenuto 3,00 su 3,00

La risposta corretta è: Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione

Tabella CASA-EDITRICE

- Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione √
- C CREATE INDEX IndexI ON CASA-EDITRICE(NumeroImpiegati) HASH
- C CREATE INDEX IndexJ ON CASA-EDITRICE(NumeroImpiegati) B+-Tree

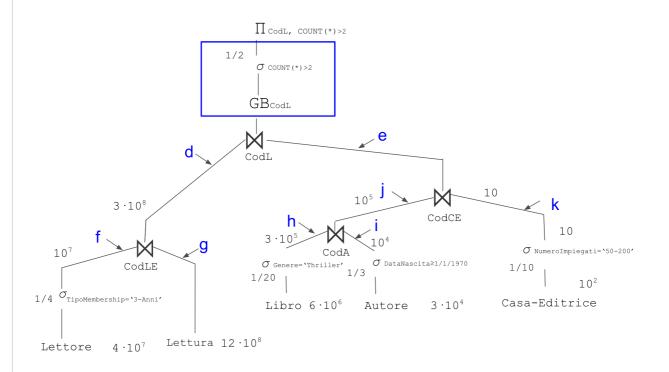
Punteggio ottenuto 3,00 su 3,00

La risposta corretta è: Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione

Anticipo Group By

(2 punti, penalità -15% per ogni risposta sbagliata)

La figura sottostante rappresenta il query tree per la query precedente.



3/15/24 12:07 PM Pagina 14 di 40

Analizzare l'anticipazione della GROUP BY GROUP BY L.CodL HAVING

COUNT(*)>2 rappresentata nel riquadro. Selezionare la soluzione che consente la massima riduzione di cardinalità (se esiste).

- C E' possibile anticiparla nel ramo d
- O Non e' possibile anticipare la Group BY GROUP BY L.CodL HAVING COUNT(*)>2
- C E' possibile anticiparla nel ramo f
- C E' possibile anticiparla nel ramo e
- C E' possibile anticiparla nel ramo h
- C E' possibile anticiparla nel ramo i
- C E' possibile anticiparla nel ramo k
- C E' possibile anticiparla nel ramo g

Punteggio ottenuto -3,00 su 20,00

La risposta corretta è: E' possibile anticiparla nel ramo d

- 1) La risposta corretta è : 10⁴
- 2) La risposta corretta è : 5 ·10°
- 3) La risposta corretta è : 10
- 4) La risposta corretta è : Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione
- 5) La risposta corretta è : Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione
- 6) La risposta corretta è : CREATE INDEX IndexE ON LIBRO(Genere) HASH
- 7) La risposta corretta è : Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione
- 8) La risposta corretta è : Nessuna strutture fisica accessoria su questa tabella migliorerebbe le prestazioni della interrogazione
- 9) La risposta corretta è : E' possibile anticiparla nel ramo d

Domanda 8

Completo

3/15/24 12:07 PM Pagina 15 di 40

5 punti (nessuna penalità per risposta sbagliata)

Un'azienda turistica che possiede diversi villaggi vuole analizzare il rendimento di ciascun villaggio. I villaggi sono dislocati in diverse aree del mondo, di cui sono note le informazioni geografiche (città, provincia, regione, stato). Per ogni villaggio sono noti a priori i servizi che potrebbero essere offerti (ristorazione, animazione e baby parking), memorizzati sotto forma di configurazione booleana.

Le tariffe dipendono dalla tipologia di alloggio (ad esempio bungalow, bilocale, trilocale) e dalla settimana. Le settimane sono raggruppate in periodi (per esempio, periodo di alta stagione). Per i clienti dei villaggi si considera l'informazione geografica di provenienza (città, provincia, regione, stato). E' inoltre memorizzato il metodo di pagamento (carta di credito, bonifico, assegno).

Si analizzano le informazioni sull'incasso e sul numero di ospiti con granularità giornaliera. Inoltre si considerano mese, trimestre (3M), quadrimestre (4M), semestre (6M), anno.

Il data warehouse è caratterizzato dal seguente schema concettuale e dal corrispondente schema logico.

VILLAGGIO(<u>CodV</u>, Villaggio, CittàV, ProvinciaV, RegioneV, StatoV, Ristorazione, Animazione, BabyP arking)

TEMPO(CodT, Data, Mese, 3M, 4M, 6M, Anno, Settimana, Periodo)

JUNK-ALLOGGIO-PAGAMENTO(**CodAP**, TipologiaAlloggio, ModalitàPagamento)

CARATTERISTICHE-CLIENTE(CodCC, CittàCliente, ProvinciaC, RegioneC, StatoC)

GESTIONE-VILLAGGI(CodV, CodT, CodAP, CodCC, Incasso, NumOspiti)

Dato lo schema logico precedente, considerare le seguenti query di interesse:

- a. Separatamente per anno, regione di provenienza del cliente (attributo RegioneC) e modalità di pagamento, visualizzare il numero complessivo di ospiti e l'incasso totale.
- b. Per i clienti provenienti dalla Germania (attributo StatoC), visualizzare l'incasso cumulativo annuale al trascorrere dei trimestri (attributo 3M).
- c. Separatamente per quadrimestre (attributo 4M), considerando la tipologia di alloggio 'trilocale', visualizzare il numero totale di ospiti e il numero medio di ospiti per regione di provenienza del cliente (attributo RegioneC).

Dato lo schema logico precedente, si svolgano le seguenti attività

1. Definire una vista materializzata con CREATE MATERIALIZED VIEW, in modo da ridurre il tempo di risposta delle query di interesse da (a) a (c) sopra riportate. In particolare si

3/15/24 12:07 PM Pagina 16 di 40

specifichi la query SQL associata al Blocco A nella seguente istruzione:

CREATE MATERIALIZED VIEW ViewVillaggi BUILD IMMEDIATE REFRESH FAST ON COMMIT AS

Blocco A

- 2. Definire l'**insieme minimale** di attributi che permette di identificare le tuple appartenenti alla vista materializzata ViewVillaggi.
- 3. Si ipotizzi che la gestione della vista materializzata (tabella derivata) sia svolta mediante trigger. Scrivere il trigger per propagare le modifiche alla vista materializzata ViewVillaggi in caso di inserimento di un nuovo record nella tabella dei fatti GESTIONE-VILLAGGI.

1)

SELECT Anno, Mese, 3M, 4M, RegioneC, StatoC, ModalitàPagamento,

SUM(NumOspiti) AS Ospiti_totali,

SUM(Incasso) AS Incasso totale

FROM TEMPO=T, JUNK_ALLOGGIO_PAGAMENTO=JAP, CARATTERISTICHE_CLIENTE=CC GESTIONE VILLAGGI=GV

WHERE T.CodT=GV.CodT AND GV.CodAP=JAP.CodAP AND GV.CodCC=CC.CodCC GROUP BY Anno,Mese, 3M, 4M, RegioneC, StatoC, ModalitàPagamento

2) Mese, RegioneC, StatoC, ModalitàPagamento

3)

Query di interesse:

(a) Separatamente per anno, regione di provenienza del cliente (attributo RegioneC) e modalità di pagamento, visualizzare il numero complessivo di ospiti e l'incasso totale.

SELECT Anno, RegioneC, ModalitàPagamento, SUM(NumOspiti), SUM(Incasso)

FROM CARATTERISTICHE-CLIENTE CC, JUNK-ALLOGGIO-PAGAMENTO JAP, TEMPO T,

GESTIONE-VILLAGGI G

WHERE < join>

GROUP BY Anno, RegioneC, ModalitàPagamento

(b) Per i clienti provenienti dalla Germania (attributo StatoC), visualizzare l'incasso cumulativo annuale al trascorrere dei trimestri (attributo 3M).

SELECT 3M, Anno, SUM(SUM(Incasso)) OVER (PARTITION BY Anno ORDER BY 3M

3/15/24 12:07 PM Pagina 17 di 40

ROWS UNBOUNDED PRECEDING)

FROM CARATTERISTICHE-CLIENTE CC, TEMPO T, GESTIONE-VILLAGGI G WHERE <join> AND StatoC = 'Germania' GROUP BY 3M, Anno

(c) Separatamente per quadrimestre (attributo 4M), considerando la tipologia di alloggio 'trilocale', visualizzare il numero totale di ospiti e il numero medio di ospiti per regione di provenienza del cliente (attributo RegioneC).

SELECT 4M, SUM(NumOspiti), SUM(NumOspiti)/COUNT(DISTINCT RegioneC)
FROM CARATTERISTICHE-CLIENTE CC, JUNK-ALLOGGIO-PAGAMENTO JAP, TEMPO T,
GESTIONE-VILLAGGI G
WHERE <join> AND TipologiaAlloggio = 'trilocale'
GROUP BY 4M

1. Blocco A - Query per vista materializzata

SELECT 3M, 4M, Anno, RegioneC, StatoC, ModalitàPagamento, TipologiaAlloggio, SUM(NumeroOspiti) AS OspitiTot, SUM(Incasso) AS IncassoTot FROM CARATTERISTICHE-CLIENTE C, JUNK-ALLOGGIO-PAGAMENTO J, TEMPO T, GESTIONE-VILLAGGI G
WHERE C.CodCC = G.CodCC AND T.CodT = G.CodT AND J.CodAP = G.CodAP GROUP BY 3M, 4M, Anno, RegioneC, StatoC, ModalitàPagamento, TipologiaAlloggio

2. Identificatore

3M, 4M, RegioneC, ModalitàPagamento, TipologiaAlloggio

3. Trigger

CREATE OR REPLACE TRIGGER MaintenanceViewVillaggi AFTER INSERT ON GESTIONE-VILLAGGI FOR EACH ROW DECLARE

Var3M, Var4M, VarAnno DATE;

VarRegioneC, VarStatoC, VarModPag, VarTipoAll VARCHAR(10);

N INTEGER;

BEGIN

SELECT 3M, 4M, Anno INTO Var3M, Var4M, VarAnno FROM TEMPO
WHERE CodT = :NEW.CodT;

SELECT RegioneC, StatoC, INTO VarRegioneC, VarStatoC FROM CARATTERISTICHE-CLIENTE WHERE CodCC = :NEW.CodCC;

3/15/24 12:07 PM Pagina 18 di 40

```
SELECT ModalitàPagamento, TipologiaAlloggio INTO VarModPag, VarTipoAll
    FROM JUNK-ALLOGGIO-PAGAMENTO
    WHERE CodAP = :NEW.CodAP;
SELECT COUNT(*) INTO N
    FROM ViewVillaggi
    WHERE 3M = Var3M AND 4M = Var4M AND RegioneC = VarRegioneC AND
ModalitàPagamento = VarModPag AND TipoAlloggio = VarTipoAll;
    IF N>0 THEN
      UPDATE ViewVillaggi
      SET OspitiTot = OspitiTot + :NEW.NumOspiti, ImportoTot = ImportoTot + :NEW.Importo
      WHERE 3M = Var3M AND 4M = Var4M AND RegioneC = VarRegioneC AND
ModalitàPagamento = VarModPag AND TipoAlloggio = VarTipoAll;
    ELSE
      INSERT INTO ViewVillaggi(...) VALUES (Var3M, Var4M, VarAnno, VarRegioneC,
VarStatoC, VarModPag, VarTipoAll, :NEW.NumOspiti, :NEW.Incasso);
END IF:
END;
```

Commento:

Errori

- Attributo Mese non necessaio in def. VM
- Manca attributo Tipologia Alloggio in def. VM
- StatoC non deve essere in insieme minimale (è in gerarchia con RegioneC)
- Trigger non presente

Domanda 9

Risposta errata

Punteggio ottenuto -0,15 su 1,00

1 punto (-15% di penalità per ogni risposta sbagliata)

Documentazione

set: Aggiunge nuovi campi ai documenti. Ha la seguente forma

```
{ $set: { <newField>: <expression>, ... } }
```

match: Filtra i documenti per passare solo i documenti che soddisfano le condizioni specificate al prossimo step della pipeline. Ha la seguente forma

3/15/24 12:07 PM Pagina 19 di 40

```
{ $match: { <query> } }
```

project: Passa i documenti con i campi richiesti alla fase successiva della pipeline. I campi specificati possono essere campi esistenti nei documenti di input o nuovi campi calcolati. Ha la seguente forma:

```
{ $project: { <specification(s)> } }
```

Il seguente documento è preso da una collection MongoDB chiamata "profilo_venditore", che tiene traccia delle caratteristiche di ogni venditore su un sito di e-commerce.

```
"vendorld": "45956",
  "name": "The Mickey Hub",
  "ratings": [9, 8, 8, 9],
  "sold_items": 105,
  "location": "United States of America",
  "registration_date": new Date("2017-05-02")
}
```

Quale delle seguenti query permette di identificare i venditori che hanno un rating minimo inferiore a 6 e hanno venduto meno di 1000 prodotti. Vogliamo visualizzare solo il nome (name) e provenienza (location).

```
(a)
     db.collection.aggregate([
       {
        "$set": {
         "min_rating": {
           $min: "$ratings"
         }
        }
       },
        $match: {
         sold_items: {
           "$It": 1000
         },
         min_rating: {
          "$It": 6
         }
        }
      },
     ])
```

3/15/24 12:07 PM Pagina 20 di 40

(c)

```
db.collection.aggregate([
 {
   $match: {
    sold_items: {
     "$It": 1000
   },
    ratings: {
     "$It": 6
   }
  }
 },
   "$project": {
    _id: false,
    name: true,
    location: true
  }
 }
])
```

(d)

3/15/24 12:07 PM Pagina 21 di 40

```
db.collection.aggregate([
 {
   "$set": {
   "min_rating": {
     $min: "$ratings"
  }
 },
 {
  $match: {
   sold_items: {
     "$It": 1000
   },
    min_rating: {
     "$It": 6
   }
  }
 },
  "$project": {
   _id: false,
    name: true,
    location: true
  }
 }
])
```

(e)

3/15/24 12:07 PM Pagina 22 di 40

```
db.collection.aggregate([
 {
   $match: {
   sold_items: {
     "$lt": 1000
   },
    min_rating: {
     "$It": { $min: "$ratings" }
  }
 },
   "$project": {
    _id: false,
    name: true,
    location: true
  }
 }
])
```

(f) Nessuna risposta è corretta X

La risposta corretta è:

3/15/24 12:07 PM Pagina 23 di 40

```
db.collection.aggregate([
  "$set": {
    "min_rating": {
     $min: "$ratings"
  }
 },
 {
  $match: {
   sold_items: {
     "$lt": 1000
   },
    min_rating: {
     "$lt": 6
   }
  }
 },
  "$project": {
    _id: false,
    name: true,
    location: true
  }
 }
])
```

3/15/24 12:07 PM Pagina 24 di 40

Domanda 10

Risposta corretta

Punteggio ottenuto 1,50 su 1,50

1.5 punti (-15% di penalità per ogni risposta sbagliata)

Definizioni

Precisione(C): frazione di elementi correttamente classificati per la classe C, su tutti gli elementi assegnati a C

Recall(C): frazione di elementi correttamente classificati per la classe C, su tutti gli elementi che appartengono a C

F1-Score(C): $2 \frac{Precisione(C)*Recall(C)}{Precisione(C)+Recall(C)}$

Accuratezza: classificazioni corrette sul totale dei campioni

Stiamo lavorando su un dataset composto da 20 campioni contenente 4 differenti classi (numerate da 0 a 3). Un classificatore C predice le seguenti classi per i 20 campioni:

$$pr = [2, 0, 0, 3, 2, 0, 0, 0, 0, 2, 0, 2, 3, 1, 2, 3, 3, 2, 0, 3]$$

La classe attesa (ground truth) per ogni campione è rappresentata dal seguente vettore:

$$gt = [2, 3, 2, 0, 1, 3, 0, 3, 0, 3, 3, 2, 1, 1, 0, 0, 0, 3, 0, 3]$$

Quale delle seguenti affermazioni è vera?

- (a) Nessuna risposta è corretta
- (b) La precisione per la classe 1 è la più bassa
- (c) Nessuna precisione raggiunge lo score di 0.8
- (d) F1-Score della classe 0 è maggiore di 0.3 √
- (e) L'accuratezza supera lo 0.6
- (f) Tutte le recalls superano lo 0.5
- (g) La precisione della classe 2 è superiore a 0.4
- (h) La recall della classe 2 è più bassa della precision

La risposta corretta è: F1-Score della classe 0 è maggiore di 0.3

Domanda 11

3/15/24 12:07 PM Pagina 25 di 40

Schema concettuale (1 punto, penalità -15% per ogni risposta sbagliata)

Si vogliono analizzare le informazioni relative ai servizi offerti da una catena di copisterie presenti in europa.

Ciascuna copisteria può offrire i seguenti diversi tipi di servizi: realizzazione di brochure, volantini, calendari, stampe fotografiche e fotocopie.

Le aziende che si rivolgono ad una copisteria possono effettuare un ordine per un certo tipo di servizio (ad esempio stampa di volantini), indicando una specifica quantità (ad esempio 10.000 volantini). Le aziende possono anche specificare se sono interessate ad una modalità di realizzazione di tipo «standard» o desiderano invece una modalità «express», al fine di ottenere il prima possibile il servizio richiesto. A discrezione dell'azienda, la consegna dei prodotti realizzati può essere effettuata dalla copisteria mediante un corriere, oppure essere a carico dell'azienda stessa. Ciascuna copisteria è convenzionata con diverse società di spedizione per gestire la consegna degli ordini.

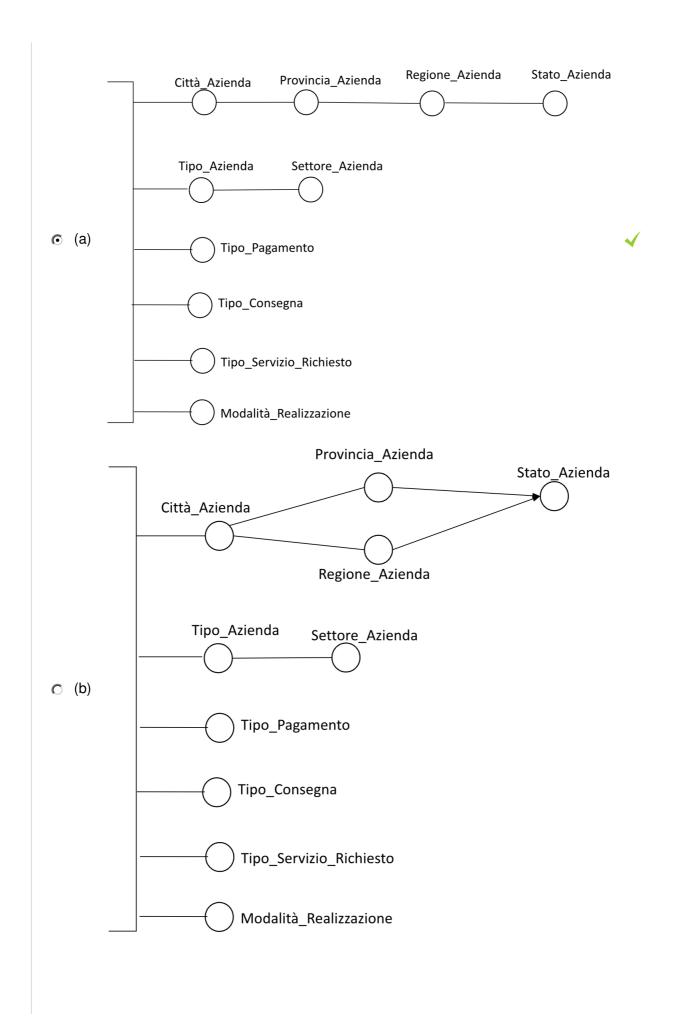
Le aziende sono caratterizzate dal tipo di azienda (quale ad esempio azienda di consulenza IT, azienda di catering, agenzia immobiliare, etc. ...) e il settore di riferimento per quel tipo di azienda (quale ad esempio settore ICT, settore food, settore immobili, etc. ...).

Si vogliono analizzare il costo medio per ordine e il tempo medio di realizzazione per ordine, in base alle seguenti informazioni:

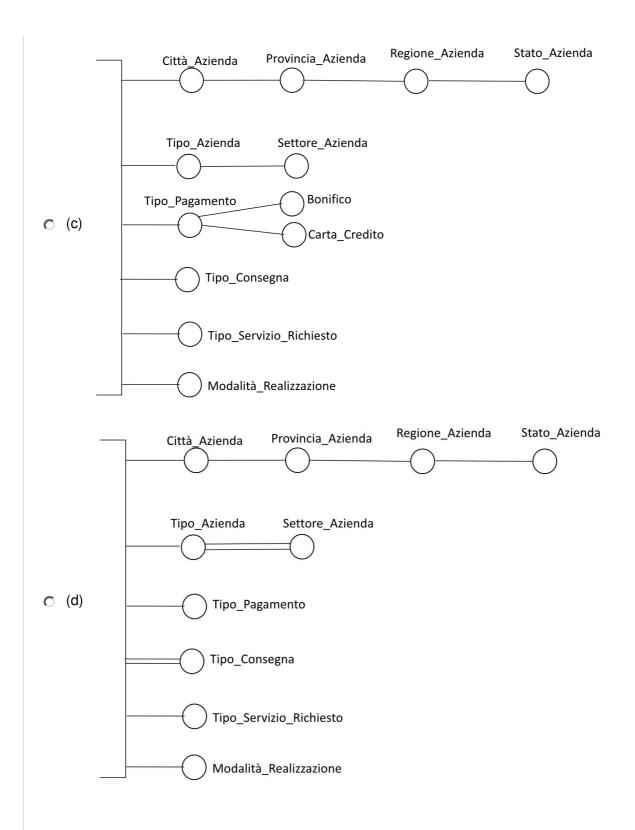
- la copisteria, i tipi di servizio disponibili presso la copisteria (uno o più valori tra «brochure», «volantini», «calendari», «stampa_foto», «fotocopie»), e la lista di tutte le società di spedizione con cui la copisteria è convenzionata. Per ciascuna copisteria è anche nota la localizzazione geografica, espressa in termini di città, provincia, regione e stato.
- il tipo di azienda che ha richiesto il servizio (ad esempio azienda di consulenza IT o azienda di catering o agenzia immobiliare, etc. ...) e il settore di riferimento per quel tipo di azienda (ad esempio settore ICT o settore food o settore immobili, etc. ...)
- localizzazione geografica dell'azienda che ha richiesto il servizio, espressa in termini di città, provincia, regione e stato
- tipo di servizio richiesto
- la modalità di realizzazione richiesta (un valore tra «standard e «express»)
- data, giorno della settimana, mese, giorno del mese, trimestre, quadrimestre, anno in cui è l'azienda ha effettuato l'ordine
- tipo di pagamento (un valore tra «bonifico» e «carta di credito»)
- tipo di consegna (un valore tra «mediante società spedizioni» e a «carico dell'azienda»)

Selezionare, tra le dimensioni proposte di seguito, quella che soddisfa le richieste descritte nelle specifiche del problema.

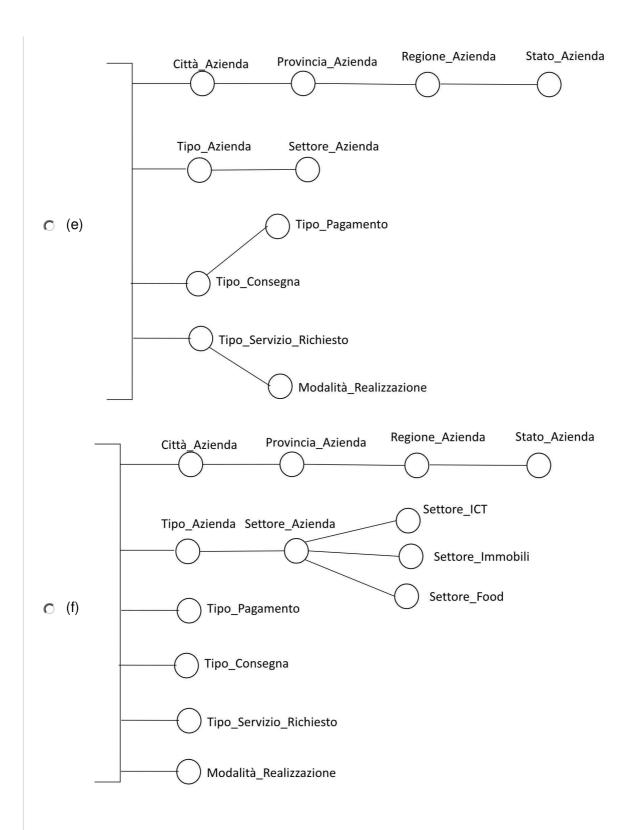
3/15/24 12:07 PM Pagina 26 di 40



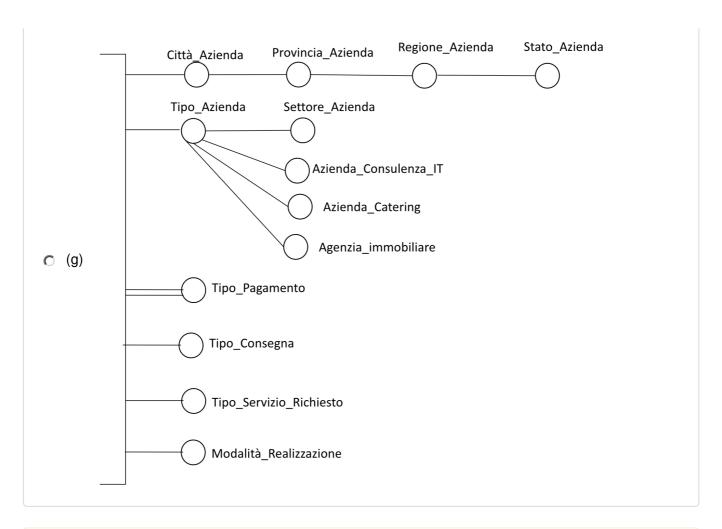
3/15/24 12:07 PM Pagina 27 di 40

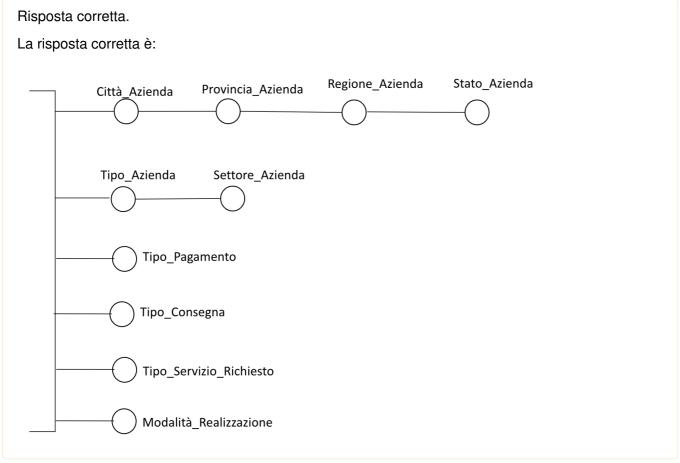


3/15/24 12:07 PM Pagina 28 di 40



3/15/24 12:07 PM Pagina 29 di 40





3/15/24 12:07 PM Pagina 30 di 40

Domanda 12

Completo

Punteggio ottenuto 2,60 su 4,00

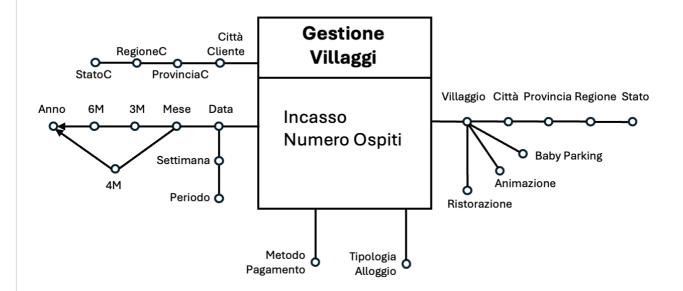
4 punti (nessuna penalità per risposta sbagliata)

Un'azienda turistica che possiede diversi villaggi vuole analizzare il rendimento di ciascun villaggio. I villaggi sono dislocati in diverse aree del mondo, di cui sono note le informazioni geografiche (città, provincia, regione, stato). Per ogni villaggio sono noti a priori i servizi che potrebbero essere offerti (ristorazione, animazione e baby parking), memorizzati sotto forma di configurazione booleana.

Le tariffe dipendono dalla tipologia di alloggio (ad esempio bungalow, bilocale, trilocale) e dalla settimana. Le settimane sono raggruppate in periodi (per esempio, periodo di alta stagione). Per i clienti dei villaggi si considera l'informazione geografica di provenienza (città, provincia, regione, stato). E' inoltre memorizzato il metodo di pagamento (carta di credito, bonifico, assegno).

Si analizzano le informazioni sull'incasso e sul numero di ospiti con granularità giornaliera. Inoltre si considerano mese, trimestre (3M), quadrimestre (4M), semestre (6M), anno.

Il data warehouse è caratterizzato dal seguente schema concettuale e dal corrispondente schema logico.



3/15/24 12:07 PM Pagina 31 di 40

VILLAGGIO(<u>CodV</u>, Villaggio, CittàV, ProvinciaV, RegioneV, StatoV, Ristorazione, Animazione, BabyP arking)

TEMPO(<u>CodT</u>, Data, Mese, 3M, 4M, 6M, Anno, Settimana, Periodo)

JUNK-ALLOGGIO-PAGAMENTO(CODAP, TipologiaAlloggio, ModalitàPagamento)

CARATTERISTICHE-CLIENTE(CodCC, CittàCliente, ProvinciaC, RegioneC, StatoC)

GESTIONE-VILLAGGI(CodV, CodT, CodAP, CodCC, Incasso, NumOspiti)

Considerando i villaggi con servizio animazione o baby parking, visualizzare per ogni città del villaggio e trimestre (3M),

- l'incasso totale e il numero medio mensile di ospiti
- la percentuale dell'incasso rispetto al complessivo considerando tutti i villaggi siti nella stessa regione
- l'incasso cumulativo dall'inizio dell'anno al trascorrere dei trimestri.

Si effettui l'analisi separatamente per modalità di pagamento.

SELECT CIttaV, 3M, ModalitàPagamento,

SUM(Incasso),

SUM(NumOspiti)/COUNT(DISTINCT Mese),

100*SUM(Incasso)/SUM(SUM(Incasso)) OVER (PARTITION BY Regione),

SUM(SUM(Incasso)) OVER (PARTITION BY ANNO ORDER BY 3M ROW PRECEDING UNBOUNDED)

FROM Villaggio=V, TEMPO=T, GESTIONE_VILLAGGI=GV

WHERE GV.CodV=V.CodV AND GV.CodT=T.CodT

AND (V.Animazione="Presente" OR V.BabyParking="Presente")

GROUP BY CittàV, 3M, ModalitàPagamento, Anno

SELECT CIttàV, 3M, ModalitàPagamento, SUM(Incasso), SUM(NumOspiti)/COUNT(DISTINCT Mese) 100*SUM(Incasso)/SUM(SUM(Incasso)) OVER (PARTITION BY RegioneV, ModalitàPagamento, 3M), SUM(SUM(Incasso)) OVER (PARTITION BY ModalitàPagamento, Città, Anno ORDER BY Trimestre ROWS UNBOUNDED PROCEEDING) FROM GESTIONE-VILLAGGIO GV, VILLAGGIO V, TEMPO T, JUNK-ALLOGGIO-PAGAMENTO JAP Where (Animazione='yes' OR

BabyParking ='yes') AND GV.CodV=V.CodV AND GV.CodT=T.CodT AND GV.CodAP=JAP.CodAP GROUP BY CIttàV, 3M, ModalitàPagamento, Anno, RegioneV

i togiono v

Commento:

Manca RegioneV nella GB

Mancano due attributi nella prima partition

3/15/24 12:07 PM Pagina 32 di 40

mancano due attributi nella seconda partition Manca un tabella

3/15/24 12:07 PM Pagina 33 di 40

Domanda 13

Risposta corretta

Punteggio ottenuto 1,00 su 1,00

1 punto (-15% di penalità per ogni risposta sbagliata)

Notazione:

Tn: Id della transazione n

B(Tn): Begin della transazione Tn

CK(Ta,Tb,...): checkpoint con transazioni Ta, Tb, ... non concluse

C(Tn): commit della transazione Tn

A(Tn): abort (rollback) della transazione Tn

Un(x): update eseguito dalla transazione Tn sull'oggetto x

In(x): insert eseguito dalla transazione Tn sull'oggetto x

Dn(x): delete eseguito dalla transazione Tn sull'oggetto x

È data la seguente sequenza di operazioni all'interno di un file di log:

B(T1), U1(C), CK(T1), D1(B), B(T3), U3(A), B(T2), U2(B), C(T3), B(T0), C(T0), CK(T1,T2), I2(A), C(T1), U2(C), A(T2), FAILURE

Quali sono gli insiemi di UNDO e REDO finali per il warm restart?

- \circ (a) redo = { }, undo = {1, 2}
- \circ (b) redo = {1, 2}, undo = {}
- \circ (c) redo = {1}, undo = {3}
- \bigcirc (d) redo = {3}, undo = {2}
- \circ (e) redo = {2, 3}, undo = {}
- (f) redo = {1}, undo = {2} √
- \circ (g) redo = {3}, undo = {1}
- (h) Nessuna delle precedenti

La risposta corretta è: redo = {1}, undo = {2}

Domanda 14

3/15/24 12:07 PM Pagina 34 di 40

Schema concettuale (1 punto, penalità -15% per ogni risposta sbagliata)

Si vogliono analizzare le informazioni relative ai servizi offerti da una catena di copisterie presenti in europa.

Ciascuna copisteria può offrire i seguenti diversi tipi di servizi: realizzazione di brochure, volantini, calendari, stampe fotografiche e fotocopie.

Le aziende che si rivolgono ad una copisteria possono effettuare un ordine per un certo tipo di servizio (ad esempio stampa di volantini), indicando una specifica quantità (ad esempio 10.000 volantini). Le aziende possono anche specificare se sono interessate ad una modalità di realizzazione di tipo «standard» o desiderano invece una modalità «express», al fine di ottenere il prima possibile il servizio richiesto. A discrezione dell'azienda, la consegna dei prodotti realizzati può essere effettuata dalla copisteria mediante un corriere, oppure essere a carico dell'azienda stessa. Ciascuna copisteria è convenzionata con diverse società di spedizione per gestire la consegna degli ordini.

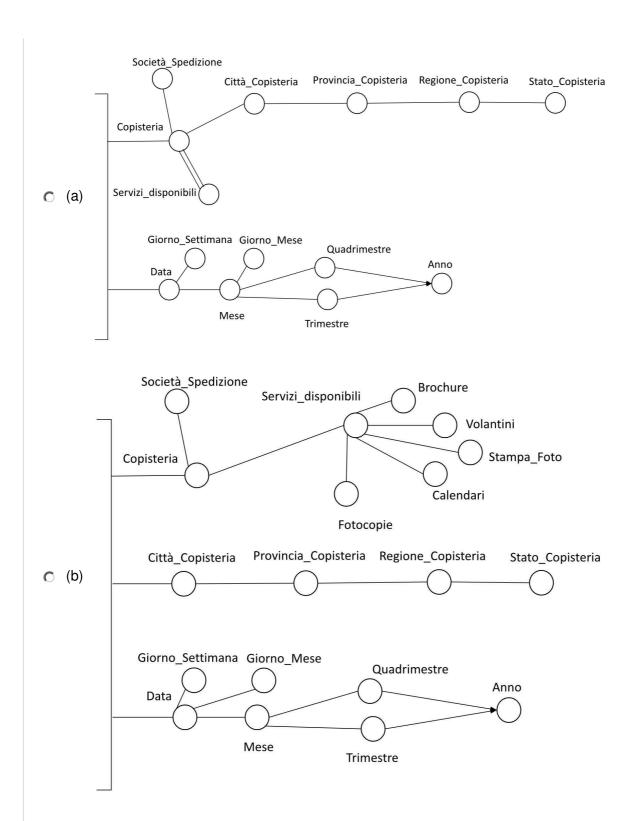
Le aziende sono caratterizzate dal tipo di azienda (quale ad esempio azienda di consulenza IT, azienda di catering, agenzia immobiliare, etc. ...) e il settore di riferimento per quel tipo di azienda (quale ad esempio settore ICT, settore food, settore immobili, etc. ...).

Si vogliono analizzare il costo medio per ordine e il tempo medio di realizzazione per ordine, in base alle seguenti informazioni:

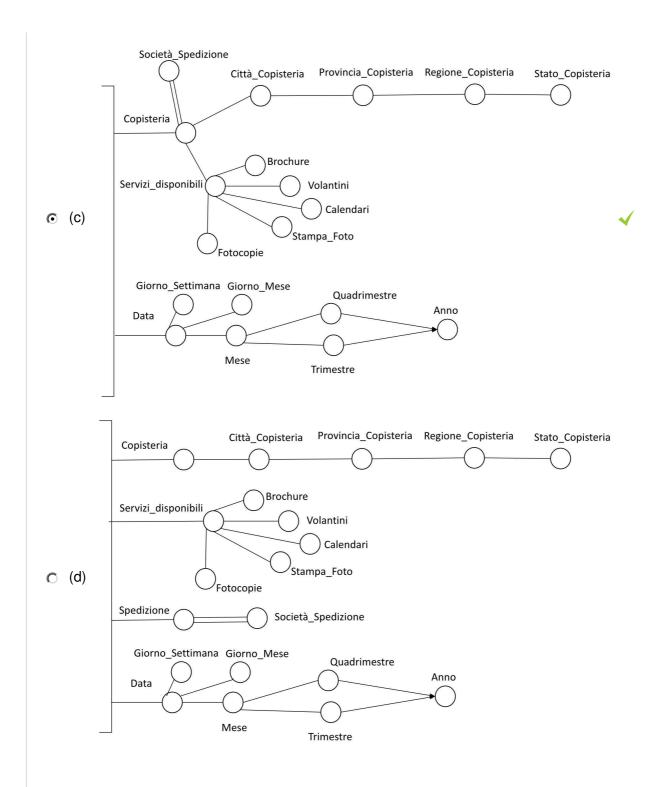
- la copisteria, i tipi di servizio disponibili presso la copisteria (uno o più valori tra «brochure», «volantini», «calendari», «stampa_foto», «fotocopie»), e la lista di tutte le società di spedizione con cui la copisteria è convenzionata. Per ciascuna copisteria è anche nota la localizzazione geografica, espressa in termini di città, provincia, regione e stato.
- il tipo di azienda che ha richiesto il servizio (ad esempio azienda di consulenza IT o azienda di catering o agenzia immobiliare, etc. ...) e il settore di riferimento per quel tipo di azienda (ad esempio settore ICT o settore food o settore immobili, etc. ...)
- localizzazione geografica dell'azienda che ha richiesto il servizio, espressa in termini di città, provincia, regione e stato
- tipo di servizio richiesto
- la modalità di realizzazione richiesta (un valore tra «standard e «express»)
- data, giorno della settimana, mese, giorno del mese, trimestre, quadrimestre, anno in cui è l'azienda ha effettuato l'ordine
- tipo di pagamento (un valore tra «bonifico» e «carta di credito»)
- tipo di consegna (un valore tra «mediante società spedizioni» e a «carico dell'azienda»)

Selezionare, tra le dimensioni proposte di seguito, quella che soddisfa le richieste descritte nelle specifiche del problema.

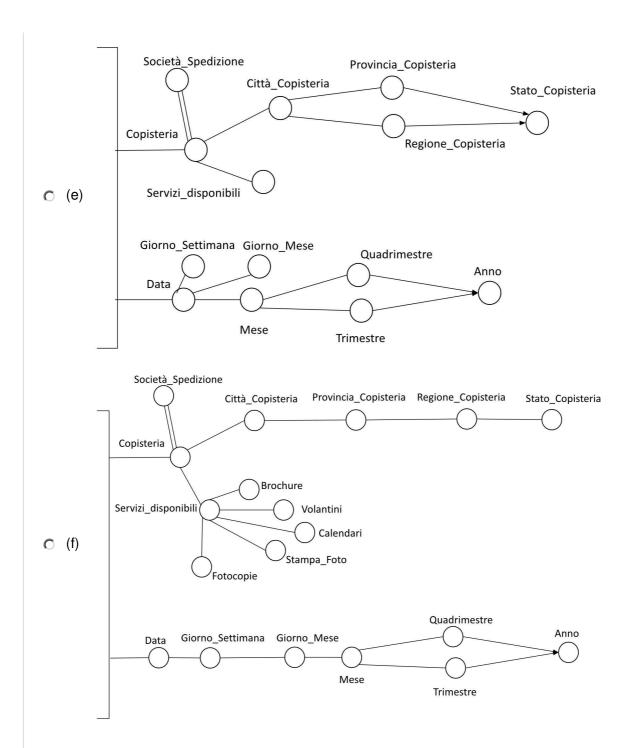
3/15/24 12:07 PM Pagina 35 di 40



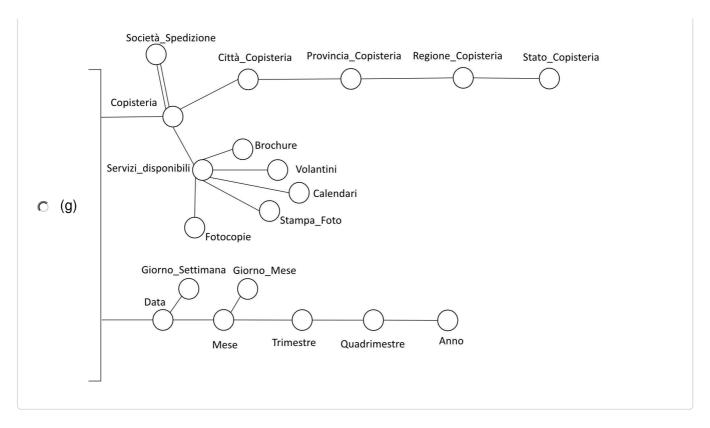
3/15/24 12:07 PM Pagina 36 di 40

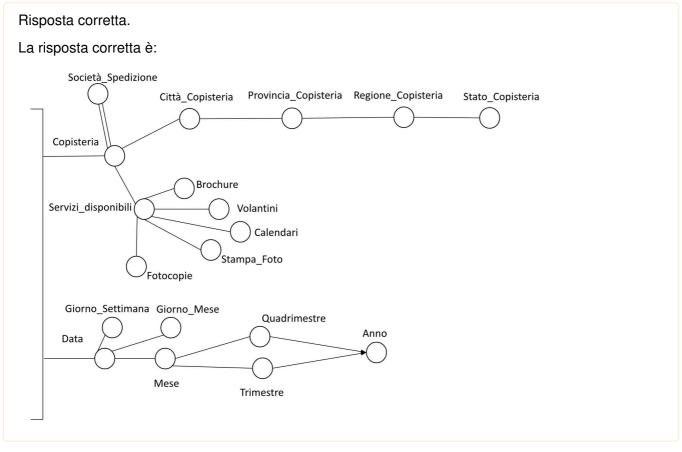


3/15/24 12:07 PM Pagina 37 di 40



3/15/24 12:08 PM Pagina 38 di 40





3/15/24 12:08 PM Pagina 39 di 40

Domanda 15

Risposta corretta

Punteggio ottenuto 1,00 su 1,00

1 punto (-15% di penalità per ogni risposta sbagliata)

Notazione:

rN(V): read dell'oggetto V da parte della transazione N

wN(V): write dell'oggetto V da parte della transazione N

Viene dato il seguente schedule S di 3 transazioni:

W2(z), R1(y), W2(z), R2(y), R0(z), W1(x), R2(y), R2(x), R0(x), W1(x)

Verificare se S è conflict serializable e, in caso affermativo, selezionare lo schedule seriale equivalente.

- \circ (a) R1(y), W1(x), W1(x), W2(z), W2(z), R2(y), R2(y), R2(x), R0(z), R0(x)
- (b) W2(z), W2(z), R2(y), R2(y), R2(x), R0(z), R0(x), R1(y), W1(x), W1(x)
- \circ (c) R0(z), R0(x), R1(y), W1(x), W1(x), W2(z), W2(z), R2(y), R2(y), R2(x)
- (d) R0(z), R0(x), W2(z), W2(z), R2(y), R2(y), R2(x), R1(y), W1(x), W1(x)
- (e) W2(z), W2(z), R2(y), R2(y), R2(x), R1(y), W1(x), W1(x), R0(z), R0(x)
- © (g) R1(y), W1(x), W1(x), R0(z), R0(x), W2(z), W2(z), R2(y), R2(y), R2(x)

La risposta corretta è: S non è conflict serializable

3/15/24 12:08 PM Pagina 40 di 40